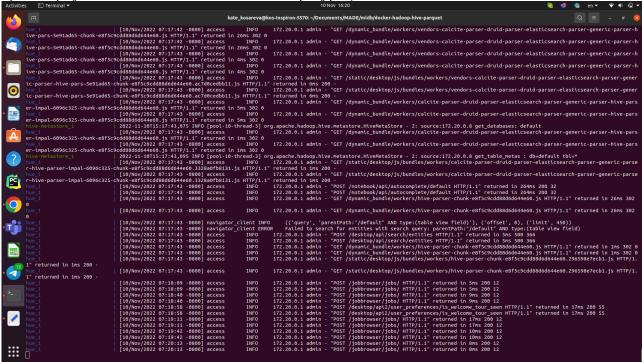
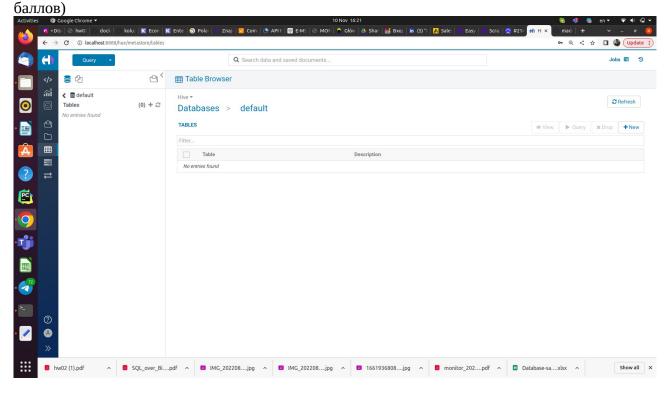
Домашнее задание 2 (Косарева Е.В, DS-12) Блок 1

1) Развернуть локальный Hive в любой конфигурации - 20 баллов

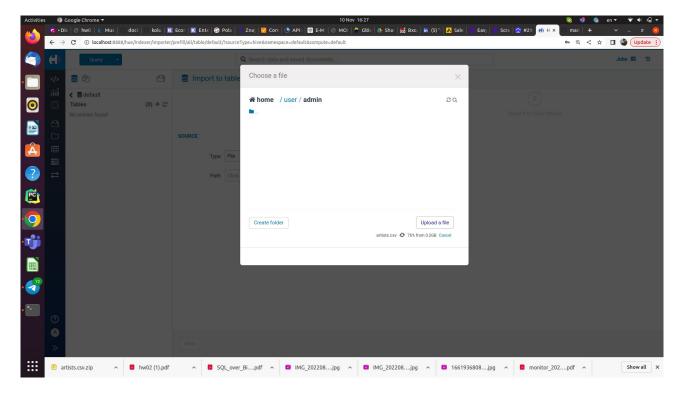


2) Подключиться к развернутому Hive с помощью любого инструмента: Hue, Python Driver, Zeppelin, любая IDE итд (15 баллов за любой инструмент, максимум 30

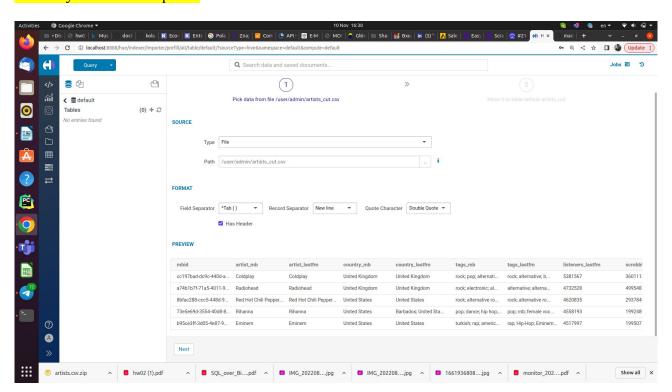


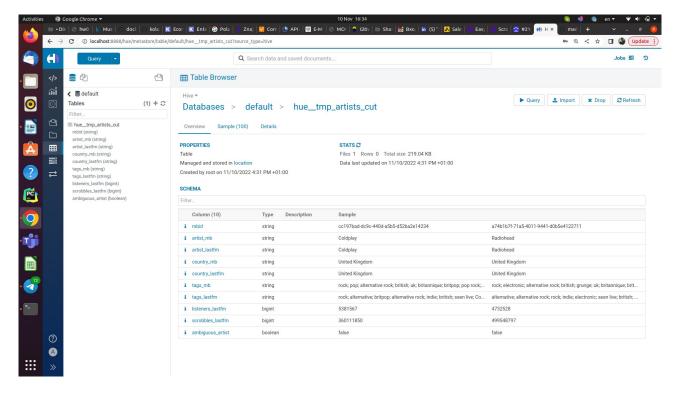
Блок 2.

1) Сделать таблицу artists в Hive и вставить туда значения, используя датасет https://www.kaggle.com/pieca111/music-artists-popularity - 15 баллов Целиком файл не загружался:

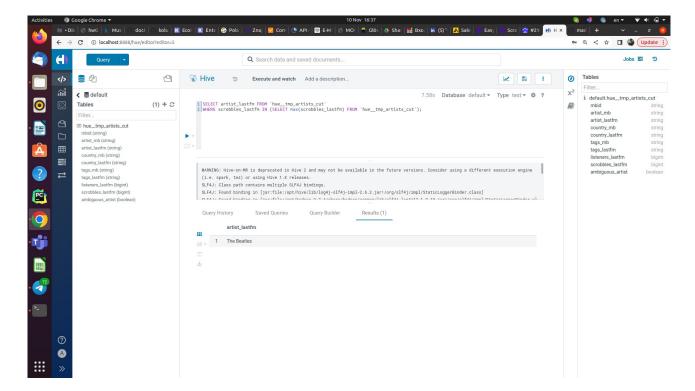


Поэтому взяла часть файла



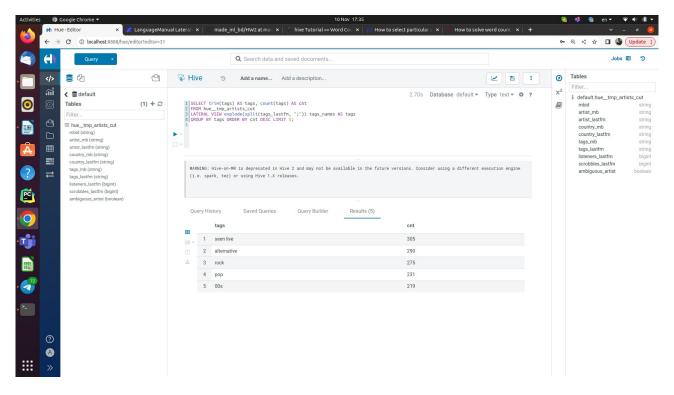


- 2) Используя Hive найти (команды и результаты записать в файл и добавить в репозиторий):
- а) Исполнителя с максимальным числом скробблов 5 баллов
 - 1 SELECT artist_lastfm FROM `hue__tmp_artists_cut`
 2 WHERE scrobbles_lastfm IN (SELECT max(scrobbles_lastfm) FROM `hue__tmp_artists_cut`);



b) Самый популярный тэг на ластфм - 10 баллов

```
SELECT trim(tags) AS tags, count(tags) AS cnt
FROM hue__tmp_artists_cut
LATERAL VIEW explode(split(tags_lastfm, ";")) tags_names AS tags
GROUP BY tags ORDER BY cnt DESC LIMIT 5;
```



- с) Самые популярные исполнители 10 самых популярных тегов ластфм 10 баллов
- d) Любой другой инсайт на ваше усмотрение 10 баллов Количество записей по странам

```
1 SELECT country_mb, count(1) AS cnt FROM hue__tmp_artists_cut
2 WHERE country_mb != '' GROUP BY country_mb ORDER BY cnt DESC LIMIT 10;
```

